PROYECTO FINAL · DEEP LEARNING Y SISTEMAS INTELIGENTES · UVG 2026

Monitoreo de fraude transaccional en producción

El modelo híbrido GRU + regresión logística del Proyecto 1, ahora como app web que cualquier analista puede usar.

José Ordoñez (231329) · José Alejandro Antón (221041) · Adrián González (23152)

PROBLEMÁTICA

El fraude que se escapa se ve en el orden

- El Banco del Altiplano detecta fraude con **variables agregadas** (montos, frecuencias, diversidad).
- Lo que se escapa sigue un **patrón en el tiempo**: compras pequeñas de prueba y luego una grande, o un cambio repentino de canal.
- En el Proyecto 1 mostramos que un modelo secuencial lo captura. Faltaba que alguien de fuera lo pudiera usar.

USUARIO

Analista de operaciones antifraude, al momento de autorizar.

DECISIÓN

Bloquear y mandar a revisión si la puntuación ≥ 0.075; si no, **Autorizar**

MODELO PLANTEADO

De dónde viene y qué cambió

PROYECTO 1 → MODELO C

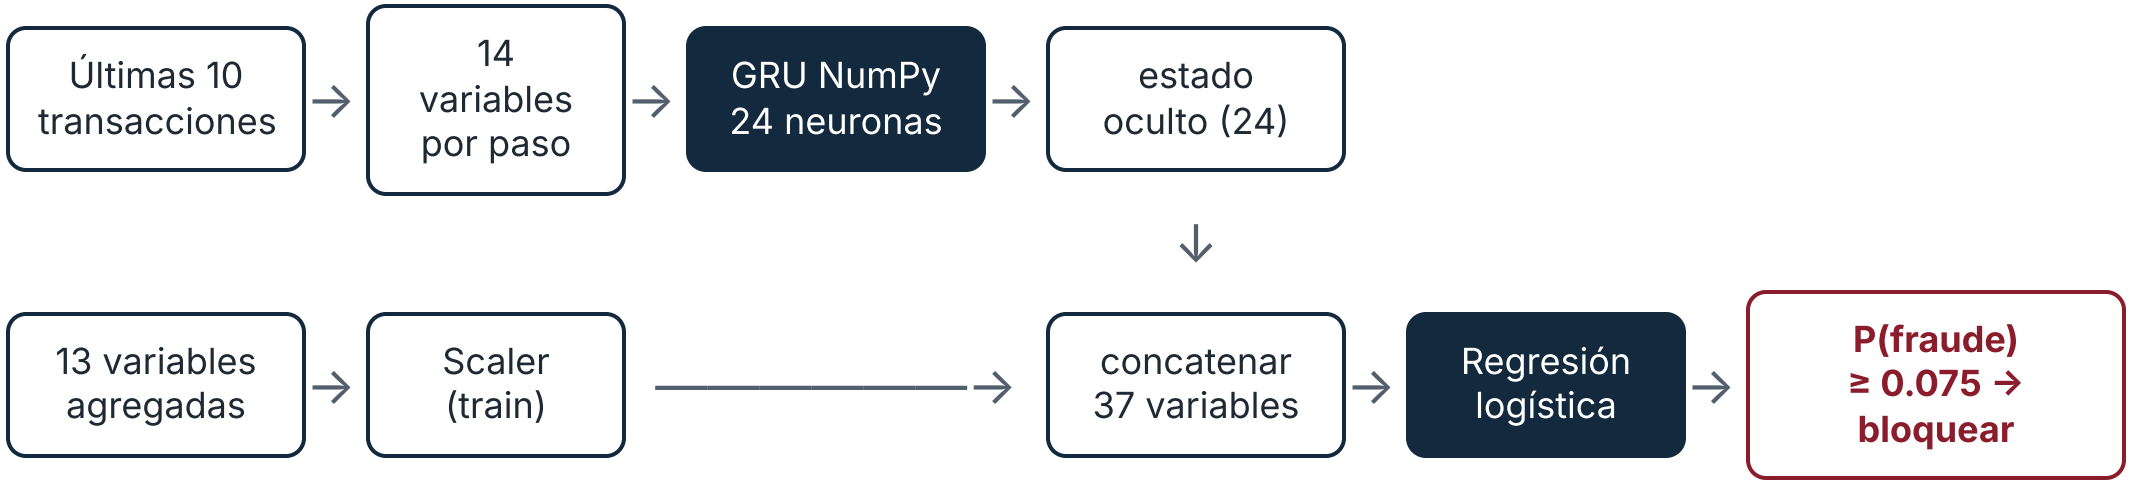
- A: agregadas (HGB) · B: GRU en NumPy · **C: estado oculto de la GRU + agregadas → regresión logística**
- C fue el mejor en validación (AUC-PR 0.922) y el candidato final.
- Datos sintéticos: 41,975 tx, 3,000 clientes, 0.715 % fraude, partición temporal.

CAMBIOS PARA PRODUCCIÓN

- **Sin reentrenar**: solo inferencia con los 5 artefactos.
- **GRU solo forward** en NumPy: sin PyTorch, imagen liviana.
- **Contrato** de entrada/salida y errores claros en `scoring.py`.
- **Semáforo** verde / ámbar / rojo sobre la decisión.
- **Umbral configurable** y **registro de uso** por predicción.

ARQUITECTURA DEL MODELO

Cómo se calcula una puntuación



Por paso: log del monto, hora en seno/coseno, log de horas desde la anterior, comercio nuevo, canal y categoría en one-hot.

Menos de 10 tx: se rellena con ceros a la izquierda, igual que en entrenamiento. Una predicción tarda ~0.4 ms.

VALIDACIÓN DE HIPÓTESIS

Criterios definidos antes de entrenar

Hipótesis	Criterio	Resultado	Veredicto
H1. El orden aporta algo que las agregadas no	AUC-PR val B > A, y cae al barajar la historia	A 0.869 → B 0.902. Al permutar: 0.819 (−9.2 %); cambio de canal 0.85 → 0.32	**Confirmada**
H2. Apuesta C: estado oculto + agregadas mejora a B	AUC-PR val C ≥ B + 0.03	C 0.922 (+0.020). No llegó, pero es el mejor modelo	**No confirmada**
H3. `scoring.py` reproduce el modelo del notebook	|Δ AUC-PR test| < 0.01, mismo umbral	0.9590 vs 0.9590; mismos TP/FP/FN; Δ máx. por puntuación 4.4e-6	**Confirmada**

Métrica principal: **AUC-PR**, porque el fraude es solo 0.7 % de los datos. Línea base: modelo A con agregadas.

MÉTRICAS CLAVE

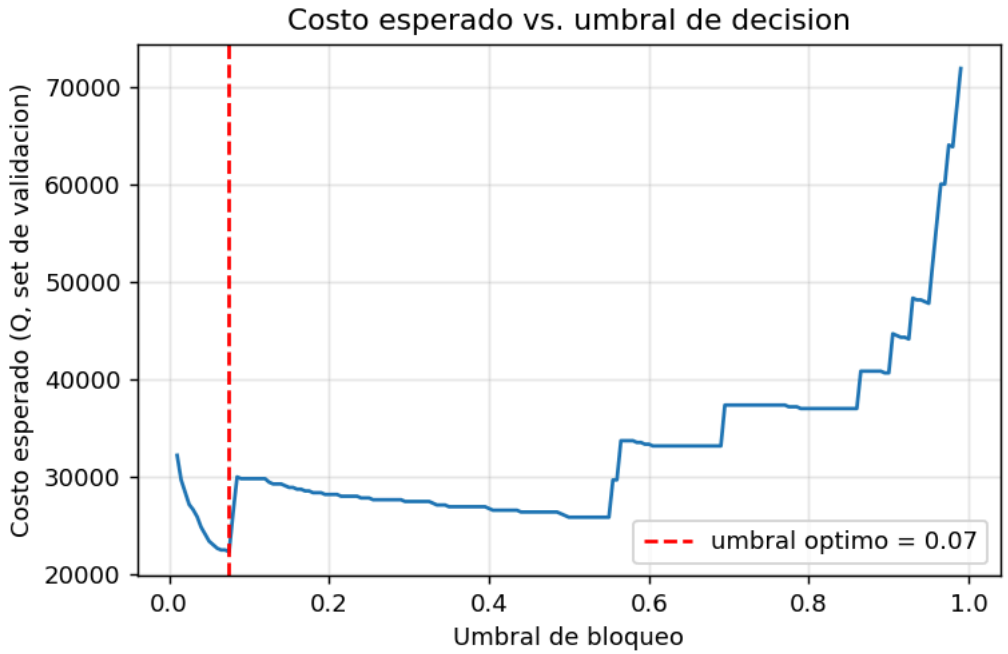
Cuánto vale en quetzales (test)

0.959
AUC-PR en test

37/39
fraudes detectados (recall 0.95)

41
falsos positivos (precisión 0.47)

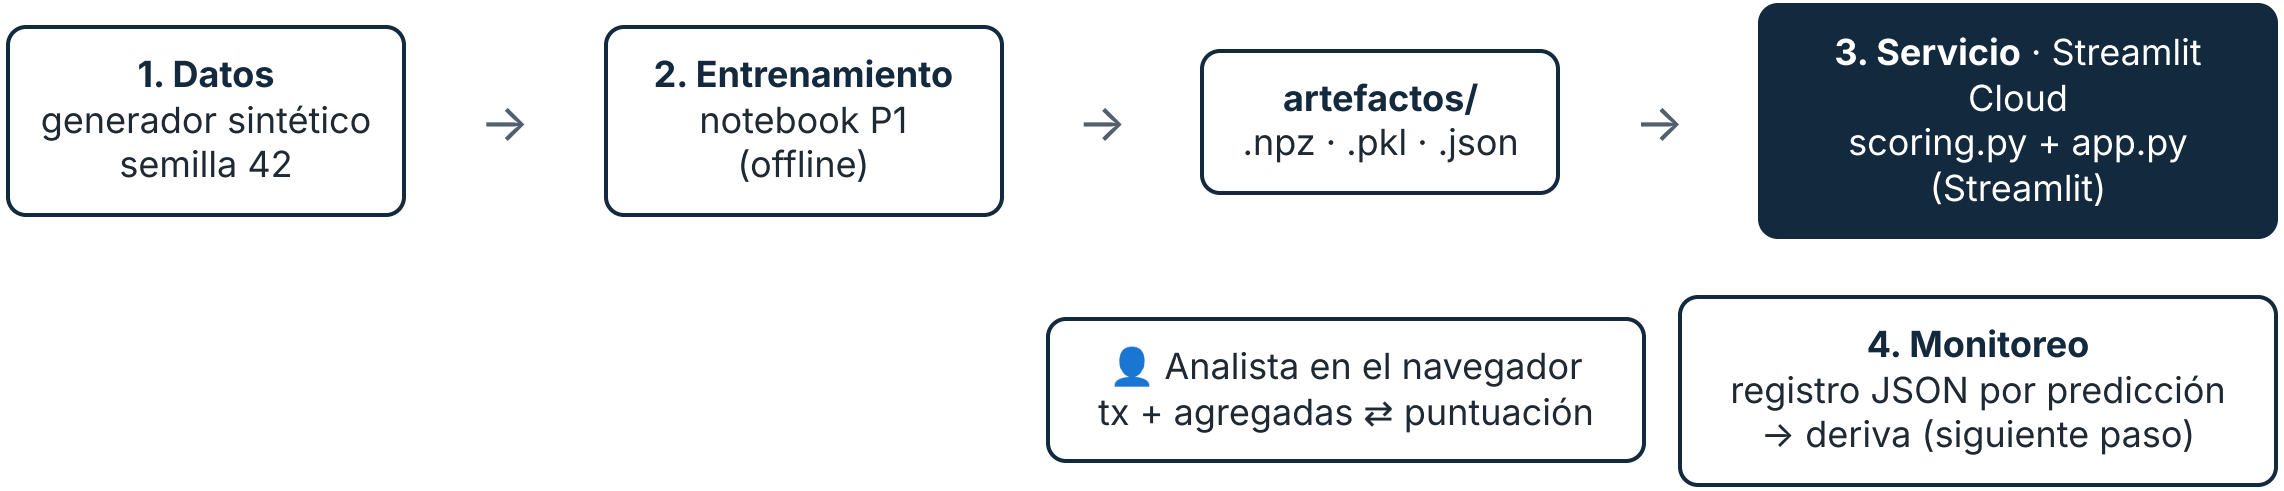
Q148K
ahorro en ~10 días (≈ Q450K/mes)



Costo: Q163,800 sin modelo → **Q15,780** con modelo. Umbral bajo a propósito: un fraude cuesta Q4,200 y un bloqueo Q180.

HERRAMIENTAS Y ARQUITECTURA

Del notebook al navegador

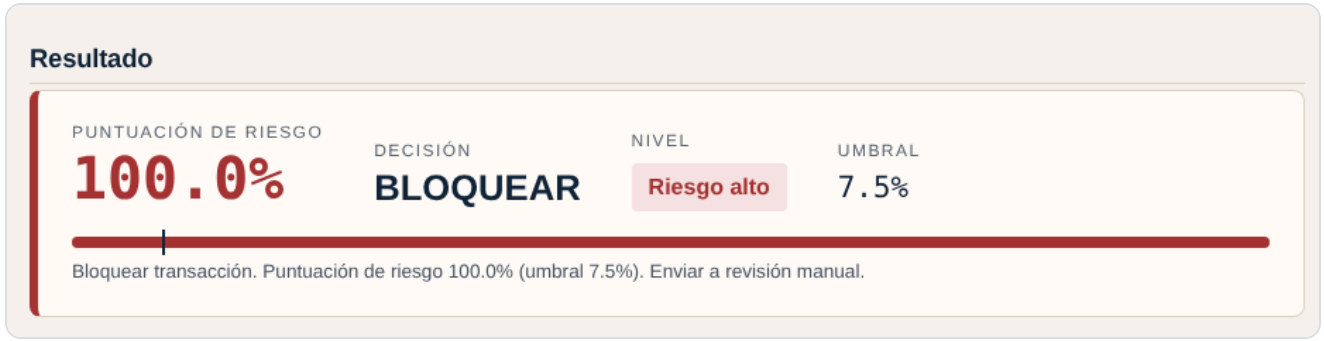


Capa	Herramienta	Por qué
Inferencia	NumPy + scikit-learn 1.3.2	Sin frameworks pesados; versiones verificadas con los artefactos
Interfaz	Streamlit	El usuario es una persona, no otro sistema
Hosting	Streamlit Community Cloud	Gratis; se conecta al repo y cada push redespliega (HF pedía plan PRO)

DEMO EN VIVO

URL_DE_LA_APP

- Elegir ejemplo **legítimo** → 2.7 %, verde, autorizar.
- Elegir **escalada rápida**: 4 compras online pequeñas en minutos y luego Q1,400 a las 3 a. m. → 100 %, rojo, bloquear.
- Mover la última fila a mano y ver cómo cambia.
- Subir un CSV incompleto → mensaje de error claro.



EVIDENCIAS DEL PASE A PRODUCCIÓN

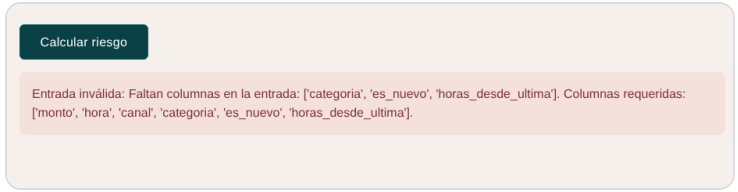
Casos, errores y registros



Legítimo · 2.7 % · autorizar



Límite · 6.3 % · ámbar



CSV sin columnas · error claro

```
{"evento": "prediccion", "n_tx": 10, "puntuacion": 0.999998, "decision": "bloquear", "semaforo": "rojo", "umbral": 0.075}
{"evento": "entrada_invalida", "origen": "Subir CSV", "detalle": "Faltan columnas en la entrada: ['categoria', ...]"}
```

En `evidencias/`: capturas, prueba documentada (3 casos válidos + 3 inválidos), AppTest de la interfaz, registro de uso y validación de `scoring.py`.

SUPUESTOS Y LIMITACIONES

Lo que hay que saber antes de confiar

- **Datos sintéticos**: el desempeño real seguramente será menor.
- **Umbral con costos hipotéticos** (Q4,200 / Q180). Es configurable.
- **Fraude sigiloso** (sin monto raro) es el más difícil: puntuación media 0.74.
- Las agregadas las calcularía el sistema del banco; en la demo se ingresan a mano.

HALLAZGO EN PRODUCCIÓN: ARRANQUE EN FRÍO

Tx en la historia	Puntuación (caso legítimo)
1	**0.707 → bloquear**
2	0.002
5	0.011
10	0.027

Con un cliente sin historia el modelo exagera. Propuesta: exigir ≥ 2 tx o regla aparte para clientes nuevos.

PRÓXIMAS ETAPAS

Recomendación al comité

Mantener en producción como apoyo al analista, con condiciones:

- Clientes con 1 sola transacción van a regla aparte.
- El bloqueo siempre pasa a revisión manual.
- Recalibrar el umbral con costos reales del banco.

- **Deriva:** comparar cada semana la distribución de puntuaciones y entradas contra entrenamiento (PSI) con el registro de uso.
- **API** (FastAPI) para que el sistema transaccional consulte directo.
- **Reentrenar con datos reales** y reforzar el fraude sigiloso.

Gracias

Preguntas

App: URL_DE_LA_APP
Repo: github.com/JoseOrdonezB/PROYECTO-FINAL