UNIVERSIDAD DEL VALLE DE GUATEMALA

Colegio Universitario



Monitoreo transaccional

Catedrático: Kevin Recinos

Jose Ordoñez– 231329

Adrián Gonzáles - 23152

Deep Learning y Sistemas Inteligentes

Sección 30

Guatemala, 2026

Introducción

Banco del Altiplano opera 1.4 millones de tarjetas de débito y crédito. Su sistema antifraude actual se construye sobre variables agregadas por ventana de tiempo: monto promedio de las últimas 24 horas, número de transacciones por hora, monto máximo del día y diversidad de comercios. El área de riesgos reporta una queja concreta y repetida: cuando los casos que se les escaparon son revisados, el patrón está ahí, no en los montos sino en el orden en que ocurrieron las operaciones.

La pregunta que este estudio responde no es si es posible entrenar un modelo de secuencias, sino si el orden de las transacciones aporta información que las variables agregadas no capturan, bajo qué condiciones y cuánto vale esa información en quetzales. Para responderla se diseñó un experimento controlado con datos sintéticos propios (Ruta A), tres modelos —una línea base sin orden (A), un modelo secuencial con GRU (B) y una apuesta híbrida (C)—, dos pruebas para aislar el valor del orden y un análisis económico que convierte el desempeño técnico en una decisión de negocio. Todos los modelos devuelven un puntaje continuo de riesgo y el umbral de bloqueo se fija después, en validación, con un criterio de costo.

Integridad de datos

Origen. Se eligió la Ruta A: un generador propio y determinístico (semilla fija 42) que reproduce siempre el mismo conjunto de datos. El universo simulado conserva la mecánica del problema real a escala reducida: 3,000 clientes con perfil propio de gasto (monto típico, comercios preferidos, canal habitual y horario), sobre cuyo fondo normal se inyectan cinco mecanismos de fraude elegidos para que no todos dependan del orden en la misma medida.

Tamaño y tasa de fraude. El conjunto contiene 41,975 transacciones a lo largo de 45 días, con una tasa de fraude global de 0.715%. Es un problema marcadamente desbalanceado, por lo que se reporta AUC-PR, precisión, exhaustividad y F1, y no exactitud como métrica principal.

Los cinco mecanismos (con su número de transacciones positivas) son:

- Escalada rápida (104 positivas): varias compras pequeñas de prueba seguidas en minutos de una compra grande. Depende del orden.
- Escalada lenta (43 positivas): el mismo patrón repartido en varios días; depende del orden y requiere más historia.
- Cambio de canal (55 positivas): el cliente casi siempre usa un canal y el fraude oscila POS → online → ATM → online en minutos. Es donde el orden importa de verdad.
- Monto atípico (48 positivas): una sola transacción con monto muy superior al habitual, sin nada raro alrededor. Caso control que no debería depender del orden.
- Fraude sigiloso (50 positivas): monto normal; solo cambia el comercio y el canal menos usados. Es el mecanismo donde se espera que el modelo falle más.

Construcción de secuencias. Cada modelo agrega variables por cliente usando solo su pasado. El modelo secuencial recibe una ventana de hasta 10 transacciones previas ordenadas (monto logarítmico, hora cíclica, tiempo desde la última operación, si el comercio es nuevo, y codificación one-hot de canal y comercio), es decir 14 variables por paso, con relleno a la izquierda cuando el cliente tiene menos historial.

Partición temporal y anti-fuga. La separación respeta el tiempo: 60% de los días más antiguos para entrenar (hasta el día 26.9; 25,185 transacciones), el 20% siguiente para validar (hasta el día 35.8; 8,395) y el último 20% para prueba (8,395). El conjunto de prueba se toca una sola vez, con el modelo y el umbral ya fijos. Las variables agregadas se escalan con un StandardScaler ajustado solo con el entrenamiento, y las variables continuas de las secuencias se normalizan con estadísticas exclusivas del entrenamiento. Ningún estadístico de validación o prueba se usa para normalizar o ajustar el modelo, lo que evita fuga de información.

Comparación común (A contra B)

Modelo A (línea base sin orden): un HistGradientBoosting sobre 13 variables agregadas causales (monto promedio 24 h, monto máximo del día, transacciones por hora, diversidad de comercios y

canales en 7 días, razón contra el promedio histórico del cliente, entre otras). Representa el techo de lo alcanzable sin leer la secuencia.

Modelo B (secuencial): un GRU binario implementado en NumPy con backpropagation through time y Adam. La implementación se verificó antes de usarla con un chequeo de gradiente numérico cuyo error relativo máximo fue de 1.7×10^{-8}. El GRU (24 unidades ocultas) recibe la secuencia ordenada de transacciones descrita arriba y genera un puntaje continuo de riesgo.

Resultado en validación. El AUC-PR del modelo A es 0.8691 y el del modelo B 0.9019: el secuencial supera a la línea base. En el umbral elegido, A alcanza precisión 0.634, exhaustividad 0.853 y F1 de 0.727; B alcanza precisión 0.619, exhaustividad 0.933 y F1 de 0.745. El modelo B recupera más fraude a costa de una precisión algo menor. Esta diferencia sugiere que el orden ayuda, pero por sí sola no es concluyente, por lo que se sometió a dos pruebas de falsificación.

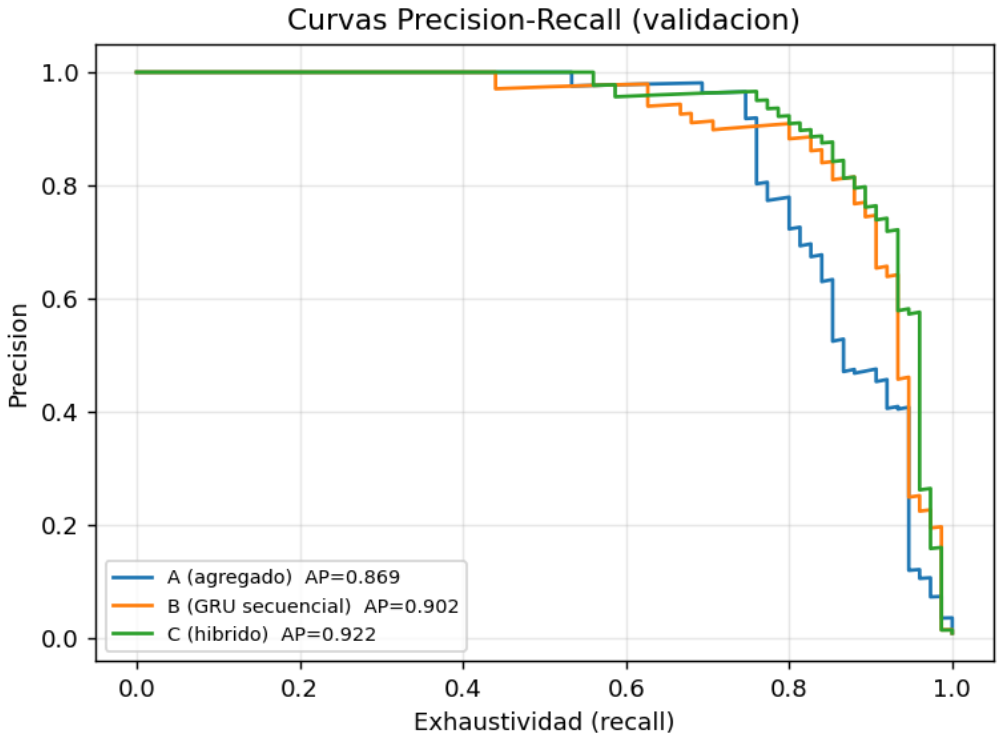


Figura 1. Curvas precisión-exhaustividad (Precision-Recall) en validación para A, B y C.

Valor del orden

Prueba 1 — Permutación controlada. Se barajó el orden de la historia de cada secuencia dejando fija la transacción evaluada y sus eventos, y se evaluó el modelo B ya entrenado sin reentrenarlo. El AUC-PR cae de 0.9019 a 0.8193, una caída relativa de 9.2%. El desplome es concentrado: el

mecanismo de cambio de canal —diseñado explícitamente como una secuencia de transiciones— baja su puntaje promedio de 0.85 a 0.32 al barajar la historia, mientras que escalada rápida, escalada lenta y monto atípico apenas cambian. Esos tres mecanismos se detectan principalmente por la composición del historial reciente (cuántas transacciones pequeñas hubo, qué tan grande es la actual), que ya es capturable con variables agregadas bien diseñadas. La conclusión correcta no es que el orden siempre aporta, sino que aporta de forma concentrada en el mecanismo que depende de transiciones.

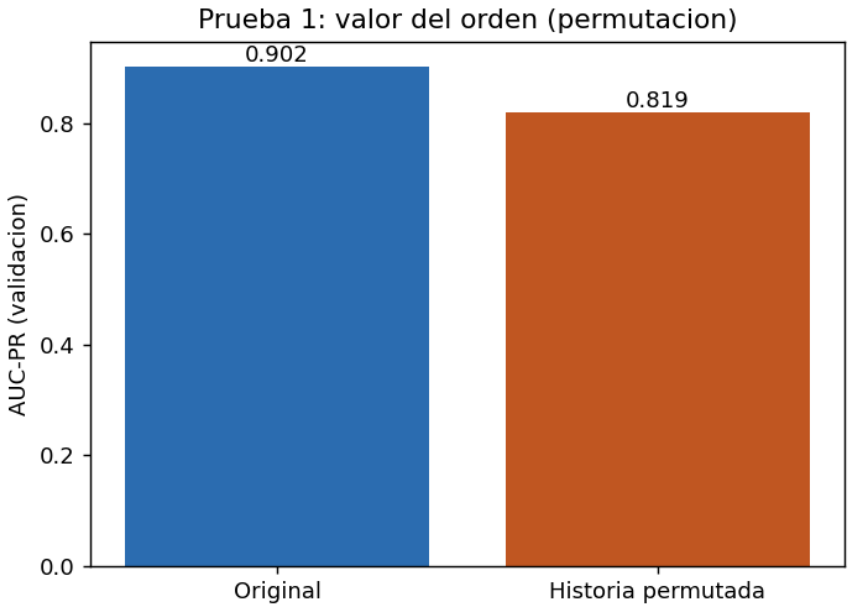


Figura 2. Prueba 1: AUC-PR con historia original frente a historia permutada.

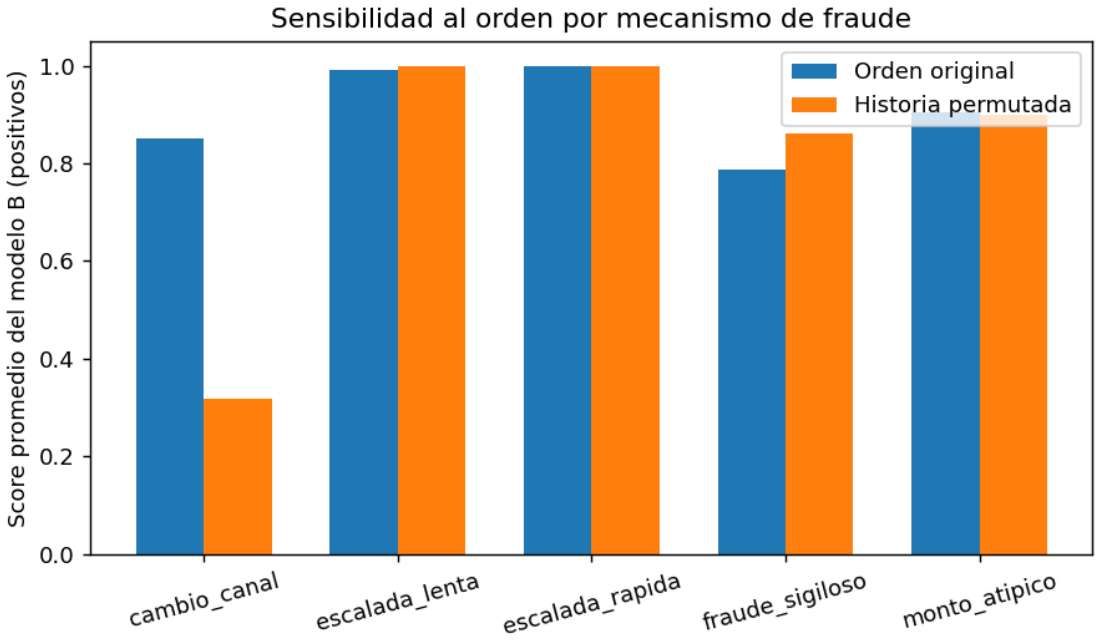


Figura 3. Sensibilidad al orden por mecanismo de fraude (puntaje promedio del modelo B).

Prueba 2 — Recortar la historia (elegida por el equipo). Se reentrenó el modelo B con ventanas de solo 2 pasos en lugar de 10. Esta prueba no destruye el orden, sino el acceso a historia lejana. El AUC-PR global es prácticamente igual (0.9019 con W=10 frente a 0.8863 con W=2), pero el desglose por mecanismo muestra el matiz: escalada lenta —que se arma a lo largo de varios días— pierde puntaje notablemente (de 0.99 a 0.84), mientras que cambio de canal mejora con menos pasos al aislar la única transición que importa. El orden y la cantidad de historia son dos recursos distintos, y cada mecanismo se apoya en uno, en otro o en ninguno: no se puede afirmar que más historia siempre ayuda.

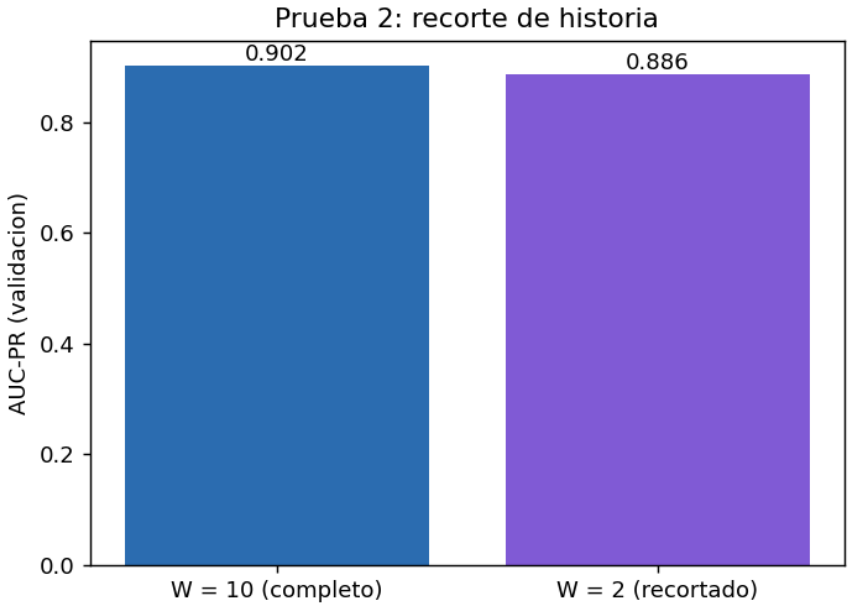


Figura 4. Prueba 2: AUC-PR con ventana completa (W=10) frente a recortada (W=2).

Apuesta del equipo (Modelo C)

Hipótesis previa. Se declaró antes de entrenar: combinar el estado oculto del GRU —el patrón secuencial— con las variables agregadas del cliente —su escala habitual de gasto— mejorará el AUC-PR sobre el modelo B solo, porque el GRU normaliza la magnitud absoluta del monto y puede perder la noción de qué tan atípico es un monto para ese cliente en particular. Se consideraría útil si el AUC-PR en validación subía al menos 0.03 respecto al modelo B.

Control y resultado. Como control se usó la misma partición, el mismo horizonte y el mismo GRU ya entrenado; el híbrido C es una regresión logística sobre el vector concatenado [estado oculto del GRU ‖ variables agregadas escaladas], ajustada solo con entrenamiento. El resultado real en

validación: el modelo B obtiene AUC-PR 0.9019 y el híbrido C 0.9217. La mejora es de +0.0198, por debajo del umbral de +0.030 que se había declarado.

Veredicto honesto: la hipótesis C no se confirma con el criterio pre-registrado. No obstante, el híbrido C sigue siendo el modelo con mejor ranking en validación (0.9217), por lo que se conserva como candidato final; la apuesta mejoró el desempeño, pero no en la magnitud prometida. Documentar este resultado sin exagerarlo es parte de la decisión presentada al comité.

Decisión económica

Los costos del enunciado son: Q4,200 por cada fraude no detectado y Q180 por bloquear una transacción legítima. El umbral de bloqueo se optimizó en validación minimizando el costo esperado; el óptimo resultó 0.075, con un costo esperado en validación de Q22,320. El umbral agresivo (bajo) refleja la gran asimetría: cuesta mucho más dejar pasar un fraude que bloquear una operación legítima.

Sobre el conjunto de prueba, usado una sola vez con el candidato final C y el umbral 0.075, el resultado fue: 37 fraudes detectados, 41 falsos positivos y 2 fraudes no detectados. El costo del modelo en el periodo de prueba (9.9 días) es de Q15,780 frente a Q163,800 si se dejara pasar todo. El ahorro en el periodo de prueba es de Q148,020, lo que proyecta un ahorro mensual estimado de Q450,334.

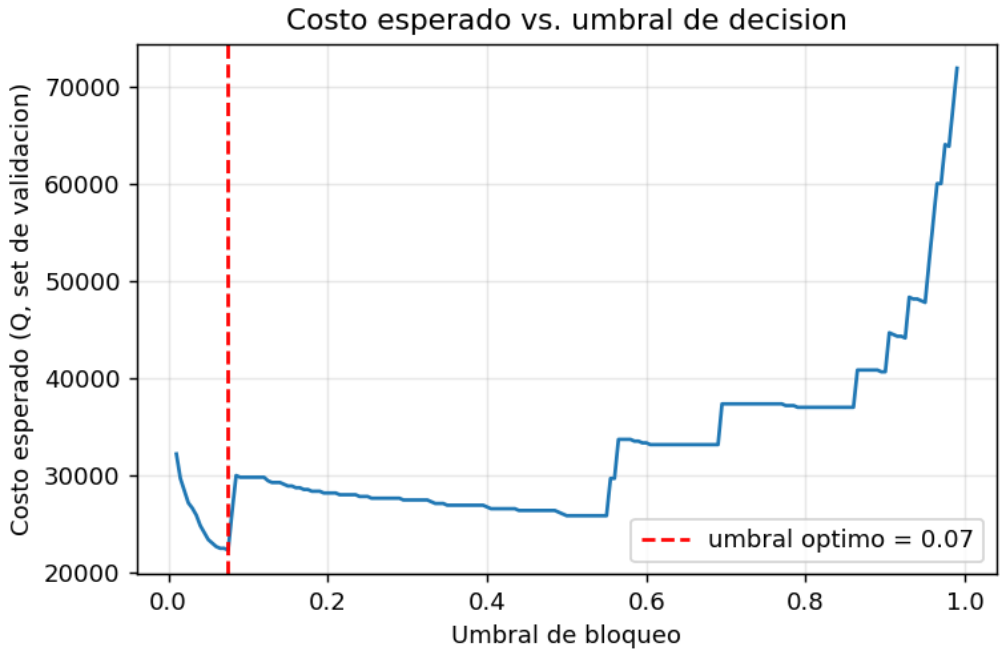


Figura 5. Costo esperado frente al umbral de decisión en el conjunto de validación.

Conviene señalarlo con claridad: el umbral 0.075 implica aceptar una precisión moderada (bloquear bastante para no dejar pasar fraude). Esa es una decisión de negocio guiada por la asimetría de costos, y debería revisarse si cambia el costo de fricción con el cliente o se obtienen cifras reales del banco.

Recomendación y límites

Recomendación. Conservar el sistema actual de variables agregadas como base y complementarlo con el modelo secuencial (el híbrido C, que además conserva el puntaje agregado). El valor del orden es real pero concentrado: aporta de forma decisiva en fraudes que se expresan como transiciones (cambio de canal), mientras que las variables agregadas ya cubren bien escalada rápida, escalada lenta y monto atípico. Un sistema que combine ambos queda más cubierto que cualquiera de los dos por separado y fue, de hecho, el de mejor ranking.

Un patrón de error concreto. El mecanismo de fraude sigiloso —monto normal, solo cambia el canal y el comercio menos usados— es donde el modelo rinde peor y donde probablemente se le escapen fraudes reales. Como no tiene monto atípico ni una estructura secuencial fuerte, capturar ese patrón exigiría una señal adicional (por ejemplo, verificación de identidad) que este proyecto no incorpora.

Límites y condiciones para cambiar la recomendación. (1) Los datos son sintéticos y a escala reducida frente a 1.4 millones de tarjetas, por lo que el desempeño reportado probablemente sea optimista. (2) Si el fraude real se parece más al mecanismo sigiloso que a los otros cuatro, la recomendación cambiaría: haría falta incorporar una señal adicional antes de confiar en el modelo. (3) El umbral se calibró con los costos hipotéticos del enunciado (Q4,200 / Q180); antes de producción habría que validarlos contra cifras reales del banco. (4) Falta evaluar la deriva de distribución si los patrones de fraude cambian con el tiempo, algo que el Proyecto Final deberá monitorear.

Matriz de evidencias

Evidencia	Figura o tabla	Conclusión	Limitación
Integridad de datos	Notebook §1–§2	41,975 tx, 0.715% de fraude, 5 mecanismos, partición temporal 60/20/20 sin fuga.	Datos sintéticos a escala reducida; desempeño posiblemente optimista.
Comparación A vs B	Figura 1 (curvas PR)	B supera a A en AUC-PR (0.9019 vs 0.8691); B recupera más a costa de precisión.	AUC-PR en validación; umbrales fijados a posteriori y optimistas.
Valor del orden (permutación)	Figuras 2 y 3	Caída relativa 9.2%; concentrada en cambio de canal (0.85→0.32).	El orden no aporta parejo a todos los mecanismos.
Valor del orden (recorte W=2)	Figura 4	Global casi igual; escalada lenta pierde, cambio de canal mejora con ventana corta.	AUC-PR global enmascara diferencias por mecanismo.
Apuesta C (híbrido)	Figura 1; celda 24	C es el mejor ranking (0.9217), pero mejora +0.0198 < +0.03 pre-registrado: NO confirmada.	La apuesta no cumplió la magnitud prometida, aunque el modelo sí mejoró.
Decisión económica	Figura 5 (costo vs umbral)	Umbral 0.075; ahorro mensual proyectado Q450,334 (test: 37 TP, 2 FN, 41 FP).	Costos hipotéticos y una sola pasada por prueba.
Recomendación	Secciones 5–7	Complementar; el orden aporta concentrado en transiciones.	Riesgo principal: fraude sigiloso, deriva y costos reales no validados.